Complément expérimental

Apprentissage de projections de correction : spécialiser a posteriori un espace d'embedding sur une base de données

Soumission anonyme

1 Contenu et périmètre

Ce complément rassemble les résultats détaillés qui ne tiennent pas dans l'article. Les expériences portent sur quatre jeux MTEB (SciFact, NFCorpus, ArguAna et SciDocs) et cinq encodeurs, soit vingt couples jeu de données–encodeur. Un *découpage* désigne la répartition des requêtes en ensembles d'entraînement, de validation et de test (60/20/20), stratifiée selon leur statut (réussie ou en erreur).

Sur le découpage initial, le protocole comprend 520 exécutions : 480 exécutions de correction, dont 468 ont abouti, et 40 exécutions des deux références non supervisées. Les 12 exécutions manquantes, par clustering sur Gemini–SciFact, ne peuvent pas être exécutées, car le nombre d'erreurs résiduelles est inférieur au nombre de clusters demandé.

Les tableaux ne portent pas tous sur les mêmes requêtes :

- le tableau S1 présente les résultats de test sur cinq découpages, selon le protocole du tableau 1 de l'article ;
- les tableaux S2 à S4 et S14 portent sur le test du découpage initial ;
- les tableaux d'ablation S5 à S12 présentent des variations calculées sur l'ensemble des requêtes du découpage initial, entraînement, validation et test confondus. Ils décrivent l'effet des réglages sur les configurations obtenues, mais ne mesurent pas la généralisation : ils ne doivent pas être comparés directement aux résultats de test.

Les notations suivent l'article. Var. : variante globale (Q) ou par clustering (C) ; *gate* : critère d'acceptation strict (S) ou adaptatif (A) ; SS : *search strictness*, c'est-à-dire le poids de préservation w_h, au niveau *error-scaled* (ES), *mid* (M) ou *relaxed* (R). Dég. compte les requêtes initialement réussies devenues en erreur ; Fix@1 compte les requêtes initialement en erreur corrigées en top-1.

2 Règle de sélection des configurations

Chaque couple compte 24 exécutions de correction abouties (12 sur Gemini–SciFact). Celle présentée pour le découpage initial est obtenue en comparant, de gauche à droite, les critères suivants calculés en validation, en faveur de la valeur la plus élevée :

$$\big(\mathbb{1}[F_{val} \geq D_{val}],\ \Delta\mathrm{NDCG}_{val},\ \Delta\mathrm{MRR}_{val},\ G_{val},\ F_{val},\ T_{val}\big),$$

où D_{val} compte les requêtes réussies dégradées, F_{val} les requêtes en erreur corrigées en top-1, G_{val} le gain de rang total et T_{val} les entrées dans le top-10. Le premier terme est la contrainte de *net correction* : une exécution doit corriger en top-1 au moins autant de requêtes en erreur qu'elle dégrade de requêtes réussies. L'inégalité large laisse éligibles les exécutions sans dégradation qui ne corrigent aucune erreur en top-1 ; leurs gains proviennent alors d'entrées dans le top-10. Treize des vingt configurations retenues n'ont aucune dégradation en validation ; les sept autres en acceptent un nombre limité en échange de corrections plus nombreuses. Le test n'intervient jamais dans cette sélection.

Cette règle compare des exécutions terminées. Elle se distingue du critère d'acceptation décrit dans l'article, qui compare les états intermédiaires (*checkpoints*) au sein d'une exécution et privilégie le gain de rang plutôt que le NDCG@10.

3 Validation croisée par découpages répétés

Pour chaque couple, les trois meilleures configurations distinctes selon la règle précédente sont réexécutées sur quatre nouveaux découpages aléatoires, soit 240 exécutions supplémentaires, dont 238 ont abouti. Les deux exécutions par clustering manquantes sur SciFact–Gemini s'arrêtent, comme prévu par l'implémentation,

lorsque le nouveau découpage d'entraînement laisse un cluster d'erreurs réduit à une seule requête. Sur chaque nouveau découpage, la même règle sélectionne une configuration en validation, puis évalue ce choix en test. Le tableau S1 agrège ces quatre résultats et celui du découpage initial.

Un test unilatéral des rangs signés de Wilcoxon sur les vingt gains moyens de NDCG@10 par couple confirme la prédominance des gains positifs ($W = 198$, $p = 6{,}7 \times 10^{-5}$). Plusieurs couples partageant un jeu de données ou un encodeur, l'indépendance des observations n'est toutefois pas assurée.

4 Comparaison aux références non supervisées

Les références *whitening* et *all-but-the-top* sont ajustées sur les embeddings du corpus et appliquées au corpus seul, avec les mêmes découpages et métriques que la méthode. Le tableau S2 résume la comparaison par jeu ; les tableaux S3 et S4 détaillent les résultats par couple. Les lignes « correction (sélection) » correspondent à la configuration retenue sur le découpage initial.

5 Ablations

Les tableaux S5 à S8 croisent les deux *gates* et les trois niveaux de *search strictness*, pour chaque variante et chaque encodeur. Les tableaux S9 à S12 présentent l'effet du nombre de clusters de la variante par clustering. Rappel : ces variations sont calculées sur l'ensemble des requêtes du découpage initial.

6 Coût de calcul et environnement

Les exécutions ont été réalisées sur une machine virtuelle sans GPU (64 vCPU Intel Xeon Ice Lake à 2,9 GHz, 256 Gio de RAM, Ubuntu Linux). Chaque exécution utilisait un seul fil de calcul BLAS (variables `OMP_NUM_THREADS` et `MKL_NUM_THREADS` fixées à 1) ; les exécutions indépendantes étaient lancées en parallèle. L'implémentation, en Python 3, utilise NumPy, PyTorch (version CPU), scikit-learn et `pytrec_eval` ; la liste des dépendances est fournie avec le code, sans versions verrouillées. Les découpages, le clustering des erreurs et l'initialisation des directions utilisent une graine fixe : 42 pour le découpage initial, 43 à 46 pour les découpages supplémentaires.

7 Dimension des embeddings, taille du corpus et taux d'erreur

Le tableau S14 rapporte, pour la configuration retenue sur le découpage initial, le gain de NDCG@10 en test sur ce découpage. En moyenne par dimension, il vaut +0,004 à 384 dimensions (4 couples), +0,013 à 1 024 (4 couples), +0,014 à 1 536 (4 couples) et +0,035 à 3 072 (8 couples). Sur les vingt couples, la corrélation de Spearman avec le gain vaut +0,34 pour le taux d'erreur initial et +0,23 pour la dimension (Pearson +0,34). La taille du corpus ne montre pas de relation cohérente (Pearson −0,09, Spearman +0,28).

Ces observations appellent trois réserves. D'abord, la dimension est confondue avec la famille de modèles : le groupe à 3 072 dimensions réunit précisément les deux modèles commerciaux les plus performants (Gemini et OpenAI-3-large). Ensuite, le taux d'erreur initial est lui-même lié à la qualité du modèle : SciFact–Gemini, avec 2 % d'erreurs initiales, ne laisse presque aucune marge de correction malgré ses 3 072 dimensions. Enfin, avec vingt couples et un seul découpage, ces corrélations décrivent les observations sans permettre de conclusion statistique par variable.

Jeu	Encodeur	Découpages	ΔNDCG@10 test	ΔMRR test	Pos	Cfg
ArguAna	Titan-v1	5	+0,0095 ± 0,0033	+0,0059 ± 0,0020	5/5	1
ArguAna	Gemini-001	5	+0,1224 ± 0,0284	+0,1496 ± 0,0390	5/5	2
ArguAna	OpenAI-3-large	5	+0,0509 ± 0,0043	+0,0403 ± 0,0025	5/5	3
ArguAna	OpenAI-3-small	5	+0,0424 ± 0,0087	+0,0355 ± 0,0033	5/5	3
ArguAna	MiniLM-L6	5	+0,0155 ± 0,0036	+0,0140 ± 0,0021	5/5	3
NFCorpus	Titan-v1	5	+0,0026 ± 0,0033	−0,0012 ± 0,0031	4/5	2
NFCorpus	Gemini-001	5	+0,0004 ± 0,0037	+0,0007 ± 0,0033	3/5	3
NFCorpus	OpenAI-3-large	5	+0,0009 ± 0,0017	+0,0007 ± 0,0033	3/5	2
NFCorpus	OpenAI-3-small	5	−0,0009 ± 0,0025	+0,0029 ± 0,0019	2/5	2
NFCorpus	MiniLM-L6	5	+0,0048 ± 0,0044	+0,0031 ± 0,0036	5/5	2
SciDocs	Titan-v1	5	+0,0008 ± 0,0026	+0,0045 ± 0,0046	4/5	3
SciDocs	Gemini-001	5	+0,0171 ± 0,0062	+0,0219 ± 0,0083	5/5	3
SciDocs	OpenAI-3-large	5	+0,0055 ± 0,0032	+0,0101 ± 0,0073	5/5	2
SciDocs	OpenAI-3-small	5	+0,0041 ± 0,0037	+0,0061 ± 0,0070	4/5	3
SciDocs	MiniLM-L6	5	−0,0027 ± 0,0013	−0,0018 ± 0,0045	0/5	3
SciFact	Titan-v1	5	+0,0147 ± 0,0146	+0,0129 ± 0,0133	5/5	2
SciFact	Gemini-001	5	−0,0003 ± 0,0011	−0,0004 ± 0,0016	1/5	3
SciFact	OpenAI-3-large	5	+0,0194 ± 0,0051	+0,0214 ± 0,0036	5/5	3
SciFact	OpenAI-3-small	5	+0,0033 ± 0,0022	+0,0038 ± 0,0023	5/5	2
SciFact	MiniLM-L6	5	+0,0108 ± 0,0085	+0,0109 ± 0,0083	5/5	2

TABLE S1 – Validation croisée par découpages aléatoires répétés. Pour chaque couple, les trois meilleures configurations en validation sur le découpage initial sont réexécutées sur quatre nouveaux découpages ; sur chacun, la configuration retenue en validation est évaluée en test. Les valeurs agrègent ces quatre résultats et celui du découpage initial (moyenne ± écart-type). Pos : découpages avec un gain de NDCG@10 en test ; Cfg : configurations différentes retenues.

Jeu	Méthode	ΔNDCG@10	ΔMRR	Couples	Dég.	Fix@1
ArguAna	correction (sélection)	+0,0579	+0,0614	5/5	0	93
ArguAna	*all-but-the-top*	−0,0125	−0,0119	1/5	22	0
ArguAna	*whitening*	−0,0162	−0,0179	2/5	27	0
NFCorpus	correction (sélection)	+0,0015	+0,0003	4/5	34	34
NFCorpus	*all-but-the-top*	−0,0202	−0,0218	1/5	154	92
NFCorpus	*whitening*	−0,1649	−0,1605	0/5	508	120
SciDocs	correction (sélection)	+0,0068	+0,0095	4/5	11	20
SciDocs	*all-but-the-top*	−0,0074	−0,0062	1/5	32	32
SciDocs	*whitening*	−0,0412	−0,0564	0/5	81	42
SciFact	correction (sélection)	+0,0149	+0,0142	4/5	4	17
SciFact	*all-but-the-top*	−0,0136	−0,0142	0/5	27	15
SciFact	*whitening*	−0,0591	−0,0521	0/5	63	29

TABLE S2 – Synthèse par jeu de la comparaison aux références non supervisées, sur le test du découpage initial. ΔNDCG@10 et ΔMRR : moyennes sur les cinq encodeurs ; Couples : encodeurs avec un gain de NDCG@10 en test ; Dég. et Fix@1 : totaux sur les cinq encodeurs des requêtes initialement réussies devenues en erreur et des requêtes initialement en erreur corrigées en top-1.

Jeu	Encodeur	Méthode	Base	ΔNDCG@10	ΔMRR	Dég.	Fix@1
ArguAna	Titan-v1	correction (sélection)	0,37/0,26	+0,0116	+0,0081	0	0
ArguAna	Titan-v1	*all-but-the-top*	0,37/0,26	−0,0033	+0,0001	0	0
ArguAna	Titan-v1	*whitening*	0,37/0,26	−0,0072	−0,0075	0	0
ArguAna	Gemini-001	correction (sélection)	0,58/0,46	+0,1626	+0,2063	0	93
ArguAna	Gemini-001	*all-but-the-top*	0,58/0,46	−0,0663	−0,0685	22	0
ArguAna	Gemini-001	*whitening*	0,58/0,46	−0,0740	−0,0829	27	0
ArguAna	OpenAI-3-large	correction (sélection)	0,41/0,28	+0,0535	+0,0401	0	0
ArguAna	OpenAI-3-large	*all-but-the-top*	0,41/0,28	+0,0000	+0,0041	0	0
ArguAna	OpenAI-3-large	*whitening*	0,41/0,28	+0,0038	−0,0023	0	0
ArguAna	OpenAI-3-small	correction (sélection)	0,40/0,28	+0,0506	+0,0401	0	0
ArguAna	OpenAI-3-small	*all-but-the-top*	0,40/0,28	+0,0094	+0,0081	0	0
ArguAna	OpenAI-3-small	*whitening*	0,40/0,28	+0,0038	+0,0068	0	0
ArguAna	MiniLM-L6	correction (sélection)	0,37/0,26	+0,0113	+0,0126	0	0
ArguAna	MiniLM-L6	*all-but-the-top*	0,37/0,26	−0,0025	−0,0031	0	0
ArguAna	MiniLM-L6	*whitening*	0,37/0,26	−0,0072	−0,0035	0	0
NFCorpus	Titan-v1	correction (sélection)	0,33/0,54	+0,0043	−0,0027	6	2
NFCorpus	Titan-v1	*all-but-the-top*	0,33/0,54	+0,0078	+0,0042	10	12
NFCorpus	Titan-v1	*whitening*	0,33/0,54	−0,0399	−0,0168	27	25
NFCorpus	Gemini-001	correction (sélection)	0,41/0,62	+0,0041	+0,0039	7	9
NFCorpus	Gemini-001	*all-but-the-top*	0,41/0,62	−0,0377	−0,0344	37	20
NFCorpus	Gemini-001	*whitening*	0,41/0,62	−0,2403	−0,2255	140	22
NFCorpus	OpenAI-3-large	correction (sélection)	0,40/0,61	+0,0012	−0,0008	6	6
NFCorpus	OpenAI-3-large	*all-but-the-top*	0,40/0,61	−0,0379	−0,0372	46	23
NFCorpus	OpenAI-3-large	*whitening*	0,40/0,61	−0,2980	−0,3612	188	13
NFCorpus	OpenAI-3-small	correction (sélection)	0,36/0,57	−0,0037	+0,0010	11	11
NFCorpus	OpenAI-3-small	*all-but-the-top*	0,36/0,57	−0,0270	−0,0240	36	21
NFCorpus	OpenAI-3-small	*whitening*	0,36/0,57	−0,1816	−0,1392	88	27
NFCorpus	MiniLM-L6	correction (sélection)	0,32/0,51	+0,0017	+0,0000	4	6
NFCorpus	MiniLM-L6	*all-but-the-top*	0,32/0,51	−0,0064	−0,0178	25	16
NFCorpus	MiniLM-L6	*whitening*	0,32/0,51	−0,0647	−0,0597	65	33

TABLE S3 – Comparaison par couple aux références non supervisées, sur le test du découpage initial (partie 1/2). Les références appliquent une transformation globale unique au corpus, sans supervision ni critère d'acceptation. Base : NDCG@10/MRR avant correction ; Dég. et Fix@1 : requêtes initialement réussies devenues en erreur et requêtes initialement en erreur corrigées en top-1.

Jeu	Encodeur	Méthode	Base	ΔNDCG@10	ΔMRR	Dég.	Fix@1
SciDocs	Titan-v1	correction (sélection)	0,21/0,36	+0,0042	+0,0095	0	3
SciDocs	Titan-v1	*all-but-the-top*	0,21/0,36	+0,0018	+0,0073	1	3
SciDocs	Titan-v1	*whitening*	0,21/0,36	−0,0051	−0,0188	6	2
SciDocs	Gemini-001	correction (sélection)	0,24/0,40	+0,0220	+0,0190	4	7
SciDocs	Gemini-001	*all-but-the-top*	0,24/0,40	−0,0085	+0,0008	8	10
SciDocs	Gemini-001	*whitening*	0,24/0,40	−0,0536	−0,0570	17	13
SciDocs	OpenAI-3-large	correction (sélection)	0,22/0,38	+0,0099	+0,0156	4	7
SciDocs	OpenAI-3-large	*all-but-the-top*	0,22/0,38	−0,0090	−0,0128	9	11
SciDocs	OpenAI-3-large	*whitening*	0,22/0,38	−0,0661	−0,1069	24	9
SciDocs	OpenAI-3-small	correction (sélection)	0,19/0,34	+0,0018	−0,0009	0	0
SciDocs	OpenAI-3-small	*all-but-the-top*	0,19/0,34	−0,0088	−0,0189	9	6
SciDocs	OpenAI-3-small	*whitening*	0,19/0,34	−0,0520	−0,0796	24	9
SciDocs	MiniLM-L6	correction (sélection)	0,20/0,35	−0,0040	+0,0044	3	3
SciDocs	MiniLM-L6	*all-but-the-top*	0,20/0,35	−0,0123	−0,0072	5	2
SciDocs	MiniLM-L6	*whitening*	0,20/0,35	−0,0293	−0,0198	10	9
SciFact	Titan-v1	correction (sélection)	0,73/0,70	+0,0323	+0,0279	1	5
SciFact	Titan-v1	*all-but-the-top*	0,73/0,70	−0,0079	+0,0029	1	4
SciFact	Titan-v1	*whitening*	0,73/0,70	−0,0301	−0,0162	3	4
SciFact	Gemini-001	correction (sélection)	0,99/0,99	+0,0000	+0,0000	0	0
SciFact	Gemini-001	*all-but-the-top*	0,99/0,99	−0,0023	−0,0031	1	0
SciFact	Gemini-001	*whitening*	0,99/0,99	−0,0446	−0,0412	10	0
SciFact	OpenAI-3-large	correction (sélection)	0,77/0,74	+0,0278	+0,0272	0	6
SciFact	OpenAI-3-large	*all-but-the-top*	0,77/0,74	−0,0189	−0,0269	10	4
SciFact	OpenAI-3-large	*whitening*	0,77/0,74	−0,1191	−0,1174	22	7
SciFact	OpenAI-3-small	correction (sélection)	0,72/0,69	+0,0065	+0,0028	2	2
SciFact	OpenAI-3-small	*all-but-the-top*	0,72/0,69	−0,0176	−0,0280	10	4
SciFact	OpenAI-3-small	*whitening*	0,72/0,69	−0,0766	−0,0714	19	9
SciFact	MiniLM-L6	correction (sélection)	0,65/0,62	+0,0077	+0,0130	1	4
SciFact	MiniLM-L6	*all-but-the-top*	0,65/0,62	−0,0211	−0,0160	5	3
SciFact	MiniLM-L6	*whitening*	0,65/0,62	−0,0251	−0,0145	9	9

TABLE S4 – Comparaison par couple aux références non supervisées, sur le test du découpage initial (partie 2/2). Les références appliquent une transformation globale unique au corpus, sans supervision ni critère d'acceptation. Base : NDCG@10/MRR avant correction ; Dég. et Fix@1 : requêtes initialement réussies devenues en erreur et requêtes initialement en erreur corrigées en top-1.

			Gate strict			*Gate* adaptatif		
Encodeur	Var.	SS	ΔNDCG@10	ΔMRR	Dég.	ΔNDCG@10	ΔMRR	Dég.
Titan-v1	Q	ES	+0,0017	+0,0012	0	+0,0000	+0,0000	0
Titan-v1	Q	M	+0,0015	+0,0010	0	+0,0000	+0,0000	0
Titan-v1	Q	R	+0,0020	+0,0013	0	+0,0000	+0,0000	0
Titan-v1	C	ES	+0,0354	+0,0204	0	+0,0000	+0,0000	0
Titan-v1	C	M	+0,0508	+0,0295	0	+0,0000	+0,0000	0
Titan-v1	C	R	+0,0522	+0,0313	0	+0,0000	+0,0000	0
Gemini-001	Q	ES	+0,0213	+0,0245	6	+0,0907	+0,1133	9
Gemini-001	Q	M	+0,0426	+0,0512	5	+0,0851	+0,1055	10
Gemini-001	Q	R	+0,0387	+0,0450	7	+0,1150	+0,1417	7
Gemini-001	C	ES	+0,0000	+0,0000	0	+0,1459	+0,1832	8
Gemini-001	C	M	+0,0367	+0,0441	5	+0,0976	+0,1207	0
Gemini-001	C	R	+0,0525	+0,0617	6	+0,1149	+0,1406	9
OpenAI-3-large	Q	ES	+0,0172	+0,0125	0	+0,0000	+0,0000	0
OpenAI-3-large	Q	M	+0,0172	+0,0128	0	+0,0000	+0,0000	0
OpenAI-3-large	Q	R	+0,0172	+0,0129	0	+0,0000	+0,0000	0
OpenAI-3-large	C	ES	+0,0736	+0,0573	0	+0,0000	+0,0000	0
OpenAI-3-large	C	M	+0,0872	+0,0681	0	+0,0000	+0,0000	0
OpenAI-3-large	C	R	+0,0857	+0,0677	0	+0,0000	+0,0000	0
OpenAI-3-small	Q	ES	+0,0151	+0,0109	0	+0,0000	+0,0000	0
OpenAI-3-small	Q	M	+0,0152	+0,0108	0	+0,0000	+0,0000	0
OpenAI-3-small	Q	R	+0,0151	+0,0107	0	+0,0000	+0,0000	0
OpenAI-3-small	C	ES	+0,0814	+0,0635	0	+0,0000	+0,0000	0
OpenAI-3-small	C	M	+0,0784	+0,0631	0	+0,0000	+0,0000	0
OpenAI-3-small	C	R	+0,0820	+0,0652	0	+0,0000	+0,0000	0
MiniLM-L6	Q	ES	+0,0106	+0,0067	0	+0,0000	+0,0000	0
MiniLM-L6	Q	M	+0,0105	+0,0069	0	+0,0000	+0,0000	0
MiniLM-L6	Q	R	+0,0106	+0,0068	0	+0,0000	+0,0000	0
MiniLM-L6	C	ES	+0,0536	+0,0366	0	+0,0000	+0,0000	0
MiniLM-L6	C	M	+0,0482	+0,0322	0	+0,0000	+0,0000	0
MiniLM-L6	C	R	+0,0592	+0,0399	0	+0,0000	+0,0000	0

TABLE S5 – Ablation du *gate* et de la *search strictness*, ArguAna. Variations calculées sur l'ensemble des requêtes du découpage initial. Var. : Q globale, C par clustering ; SS : *search strictness* (ES *error-scaled*, M *mid*, R *relaxed*) ; Dég. : requêtes initialement réussies devenues en erreur.

			Gate strict			*Gate* adaptatif		
Encodeur	Var.	SS	ΔNDCG@10	ΔMRR	Dég.	ΔNDCG@10	ΔMRR	Dég.
Titan-v1	Q	ES	+0,0000	+0,0000	0	+0,0040	+0,0018	14
Titan-v1	Q	M	+0,0014	+0,0005	17	+0,0001	+0,0005	10
Titan-v1	Q	R	+0,0000	+0,0000	0	+0,0002	+0,0005	8
Titan-v1	C	ES	+0,0000	+0,0000	0	+0,0043	+0,0008	19
Titan-v1	C	M	+0,0018	+0,0022	17	+0,0001	+0,0010	5
Titan-v1	C	R	+0,0000	+0,0000	0	+0,0000	+0,0000	0
Gemini-001	Q	ES	+0,0000	+0,0000	0	+0,0010	+0,0021	6
Gemini-001	Q	M	+0,0000	+0,0000	0	+0,0000	+0,0000	0
Gemini-001	Q	R	+0,0000	+0,0011	8	+0,0031	+0,0046	22
Gemini-001	C	ES	+0,0000	+0,0000	0	+0,0041	+0,0046	28
Gemini-001	C	M	+0,0000	+0,0000	0	+0,0008	+0,0019	63
Gemini-001	C	R	+0,0000	+0,0000	0	+0,0000	+0,0000	0
OpenAI-3-large	Q	ES	−0,0002	+0,0003	2	+0,0000	+0,0000	0
OpenAI-3-large	Q	M	+0,0000	+0,0000	0	−0,0008	−0,0004	41
OpenAI-3-large	Q	R	+0,0000	+0,0000	0	−0,0006	−0,0017	40
OpenAI-3-large	C	ES	+0,0002	+0,0012	2	−0,0011	−0,0030	33
OpenAI-3-large	C	M	+0,0000	+0,0000	0	+0,0007	+0,0005	40
OpenAI-3-large	C	R	+0,0000	+0,0000	0	+0,0000	+0,0000	0
OpenAI-3-small	Q	ES	+0,0000	+0,0000	0	+0,0000	+0,0000	0
OpenAI-3-small	Q	M	−0,0002	−0,0002	4	−0,0035	−0,0031	56
OpenAI-3-small	Q	R	+0,0000	+0,0000	0	−0,0032	−0,0022	56
OpenAI-3-small	C	ES	+0,0000	+0,0000	0	+0,0000	+0,0000	0
OpenAI-3-small	C	M	+0,0000	+0,0000	0	+0,0000	+0,0000	0
OpenAI-3-small	C	R	+0,0000	+0,0000	0	−0,0017	+0,0017	28
MiniLM-L6	Q	ES	+0,0007	+0,0006	9	+0,0030	+0,0007	37
MiniLM-L6	Q	M	+0,0000	+0,0000	0	+0,0012	+0,0009	33
MiniLM-L6	Q	R	+0,0007	+0,0017	6	+0,0000	+0,0000	0
MiniLM-L6	C	ES	+0,0000	+0,0000	0	+0,0043	+0,0052	23
MiniLM-L6	C	M	+0,0000	+0,0000	0	+0,0034	+0,0086	43
MiniLM-L6	C	R	+0,0000	+0,0000	0	+0,0030	+0,0079	44

TABLE S6 – Ablation du *gate* et de la *search strictness*, NFCorpus. Variations calculées sur l'ensemble des requêtes du découpage initial. Var. : Q globale, C par clustering ; SS : *search strictness* (ES *error-scaled*, M *mid*, R *relaxed*) ; Dég. : requêtes initialement réussies devenues en erreur.

			Gate strict			*Gate* adaptatif		
Encodeur	Var.	SS	ΔNDCG@10	ΔMRR	Dég.	ΔNDCG@10	ΔMRR	Dég.
Titan-v1	Q	ES	+0,0012	+0,0011	0	+0,0011	+0,0022	0
Titan-v1	Q	M	−0,0001	+0,0017	0	−0,0003	+0,0002	0
Titan-v1	Q	R	−0,0006	+0,0005	0	+0,0000	+0,0000	0
Titan-v1	C	ES	+0,0023	+0,0059	0	+0,0009	+0,0017	0
Titan-v1	C	M	+0,0035	+0,0094	1	+0,0001	+0,0012	0
Titan-v1	C	R	+0,0002	+0,0012	0	+0,0001	+0,0010	0
Gemini-001	Q	ES	+0,0035	+0,0040	6	+0,0249	+0,0336	21
Gemini-001	Q	M	+0,0066	+0,0074	5	+0,0220	+0,0283	12
Gemini-001	Q	R	+0,0085	+0,0114	7	+0,0035	+0,0046	4
Gemini-001	C	ES	+0,0084	+0,0089	11	+0,0313	+0,0446	25
Gemini-001	C	M	+0,0169	+0,0217	13	+0,0021	+0,0041	3
Gemini-001	C	R	+0,0000	+0,0000	0	+0,0154	+0,0194	17
OpenAI-3-large	Q	ES	+0,0110	+0,0195	3	+0,0092	+0,0135	3
OpenAI-3-large	Q	M	+0,0056	+0,0060	8	+0,0012	+0,0017	1
OpenAI-3-large	Q	R	+0,0042	+0,0046	6	+0,0008	+0,0023	1
OpenAI-3-large	C	ES	+0,0068	+0,0112	3	−0,0001	+0,0006	0
OpenAI-3-large	C	M	+0,0121	+0,0188	12	+0,0000	+0,0000	0
OpenAI-3-large	C	R	+0,0031	+0,0051	6	+0,0015	+0,0041	0
OpenAI-3-small	Q	ES	+0,0051	+0,0113	4	+0,0038	+0,0061	5
OpenAI-3-small	Q	M	+0,0031	+0,0073	6	+0,0027	+0,0051	5
OpenAI-3-small	Q	R	+0,0029	+0,0084	6	+0,0018	+0,0056	2
OpenAI-3-small	C	ES	+0,0063	+0,0113	7	+0,0000	+0,0000	0
OpenAI-3-small	C	M	+0,0045	+0,0077	5	+0,0000	+0,0010	0
OpenAI-3-small	C	R	+0,0042	+0,0103	10	+0,0000	+0,0000	0
MiniLM-L6	Q	ES	+0,0000	+0,0000	0	+0,0000	+0,0000	0
MiniLM-L6	Q	M	−0,0001	+0,0011	2	+0,0000	+0,0000	0
MiniLM-L6	Q	R	−0,0014	−0,0004	6	−0,0004	+0,0028	4
MiniLM-L6	C	ES	+0,0000	+0,0000	0	+0,0000	+0,0000	0
MiniLM-L6	C	M	−0,0016	−0,0009	8	+0,0000	+0,0000	0
MiniLM-L6	C	R	−0,0005	+0,0006	6	+0,0000	+0,0000	0

TABLE S7 – Ablation du *gate* et de la *search strictness*, SciDocs. Variations calculées sur l'ensemble des requêtes du découpage initial. Var. : Q globale, C par clustering ; SS : *search strictness* (ES *error-scaled*, M *mid*, R *relaxed*) ; Dég. : requêtes initialement réussies devenues en erreur.

			Gate strict			*Gate* adaptatif		
Encodeur	Var.	SS	ΔNDCG@10	ΔMRR	Dég.	ΔNDCG@10	ΔMRR	Dég.
Titan-v1	Q	ES	+0,0008	+0,0011	2	+0,0000	+0,0000	0
Titan-v1	Q	M	+0,0054	+0,0043	2	+0,0000	+0,0000	0
Titan-v1	Q	R	+0,0116	+0,0095	0	+0,0000	+0,0000	0
Titan-v1	C	ES	+0,0100	+0,0108	0	+0,0000	+0,0000	0
Titan-v1	C	M	+0,0054	+0,0056	0	+0,0000	+0,0000	0
Titan-v1	C	R	+0,0137	+0,0101	0	+0,0000	+0,0000	0
Gemini-001	Q	ES	+0,0010	+0,0021	1	+0,0000	+0,0000	0
Gemini-001	Q	M	+0,0010	+0,0021	1	+0,0000	+0,0000	0
Gemini-001	Q	R	+0,0016	+0,0029	2	+0,0000	+0,0000	0
Gemini-001	C	ES	+0,0019	+0,0029	1	+0,0000	+0,0000	0
Gemini-001	C	M	+0,0014	+0,0019	0	+0,0000	+0,0000	0
Gemini-001	C	R	+0,0019	+0,0029	1	+0,0000	+0,0000	0
OpenAI-3-large	Q	ES	+0,0214	+0,0239	3	+0,0067	+0,0050	4
OpenAI-3-large	Q	M	+0,0181	+0,0180	5	+0,0094	+0,0080	5
OpenAI-3-large	Q	R	+0,0074	+0,0056	7	+0,0084	+0,0069	6
OpenAI-3-large	C	ES	+0,0469	+0,0450	2	+0,0103	+0,0092	4
OpenAI-3-large	C	M	+0,0119	+0,0094	6	+0,0032	+0,0029	6
OpenAI-3-large	C	R	+0,0188	+0,0162	5	+0,0042	+0,0040	7
OpenAI-3-small	Q	ES	+0,0035	+0,0056	1	+0,0000	+0,0000	0
OpenAI-3-small	Q	M	−0,0014	−0,0005	5	+0,0000	+0,0000	0
OpenAI-3-small	Q	R	−0,0001	+0,0008	3	+0,0000	+0,0000	0
OpenAI-3-small	C	ES	+0,0009	+0,0010	4	+0,0000	+0,0000	0
OpenAI-3-small	C	M	+0,0072	+0,0069	5	+0,0000	+0,0000	0
OpenAI-3-small	C	R	+0,0042	+0,0030	8	+0,0000	+0,0000	0
MiniLM-L6	Q	ES	+0,0115	+0,0139	1	+0,0000	+0,0000	0
MiniLM-L6	Q	M	+0,0071	+0,0068	4	+0,0000	+0,0000	0
MiniLM-L6	Q	R	+0,0048	+0,0039	5	+0,0000	+0,0000	0
MiniLM-L6	C	ES	+0,0107	+0,0116	3	+0,0000	+0,0000	0
MiniLM-L6	C	M	+0,0182	+0,0204	4	+0,0000	+0,0000	0
MiniLM-L6	C	R	+0,0199	+0,0199	7	+0,0000	+0,0000	0

TABLE S8 – Ablation du *gate* et de la *search strictness*, SciFact. Variations calculées sur l'ensemble des requêtes du découpage initial. Var. : Q globale, C par clustering ; SS : *search strictness* (ES *error-scaled*, M *mid*, R *relaxed*) ; Dég. : requêtes initialement réussies devenues en erreur.

Encodeur	*Gate*	SS	$k = 3$	$k = 5$	$k = 10$
Titan-v1	S	ES	+0,0415	+0,0400	+0,0354
Titan-v1	S	M	+0,0508	+0,0392	+0,0364
Titan-v1	S	R	+0,0522	+0,0387	+0,0328
Titan-v1	A	ES	+0,0000	+0,0000	+0,0000
Titan-v1	A	M	+0,0000	+0,0000	+0,0000
Titan-v1	A	R	+0,0000	+0,0000	+0,0000
Gemini-001	S	ES	+0,0000	+0,0011	+0,0225
Gemini-001	S	M	+0,0480	+0,0367	+0,0285
Gemini-001	S	R	+0,0370	+0,0525	+0,0312
Gemini-001	A	ES	+0,1459	+0,1330	+0,1508
Gemini-001	A	M	+0,0881	+0,0778	+0,0976
Gemini-001	A	R	+0,0977	+0,1149	+0,0954
OpenAI-3-large	S	ES	+0,0788	+0,0819	+0,0736
OpenAI-3-large	S	M	+0,0870	+0,0872	+0,0771
OpenAI-3-large	S	R	+0,0870	+0,0857	+0,0801
OpenAI-3-large	A	ES	+0,0000	+0,0000	+0,0000
OpenAI-3-large	A	M	+0,0000	+0,0000	+0,0000
OpenAI-3-large	A	R	+0,0000	+0,0000	+0,0000
OpenAI-3-small	S	ES	+0,0814	+0,0763	+0,0658
OpenAI-3-small	S	M	+0,0784	+0,0806	+0,0616
OpenAI-3-small	S	R	+0,0820	+0,0751	+0,0633
OpenAI-3-small	A	ES	+0,0000	+0,0000	+0,0000
OpenAI-3-small	A	M	+0,0000	+0,0000	+0,0000
OpenAI-3-small	A	R	+0,0000	+0,0000	+0,0000
MiniLM-L6	S	ES	+0,0500	+0,0535	+0,0536
MiniLM-L6	S	M	+0,0496	+0,0522	+0,0482
MiniLM-L6	S	R	+0,0526	+0,0592	+0,0465
MiniLM-L6	A	ES	+0,0000	+0,0000	+0,0000
MiniLM-L6	A	M	+0,0000	+0,0000	+0,0000
MiniLM-L6	A	R	+0,0000	+0,0000	+0,0000

TABLE S9 – Sensibilité au nombre de clusters k de la variante par clustering, ArguAna. Variations de NDCG@10 calculées sur l'ensemble des requêtes du découpage initial. *Gate* : S strict, A adaptatif ; SS : *search strictness* (ES, M, R).

Encodeur	*Gate*	SS	$k = 3$	$k = 5$	$k = 10$
Titan-v1	S	ES	+0,0000	+0,0000	+0,0000
Titan-v1	S	M	+0,0012	+0,0018	+0,0000
Titan-v1	S	R	+0,0000	+0,0012	+0,0007
Titan-v1	A	ES	+0,0043	+0,0005	+0,0002
Titan-v1	A	M	+0,0001	+0,0001	+0,0001
Titan-v1	A	R	+0,0000	+0,0003	+0,0000
Gemini-001	S	ES	+0,0000	+0,0000	+0,0000
Gemini-001	S	M	+0,0000	+0,0000	+0,0000
Gemini-001	S	R	+0,0000	+0,0000	+0,0006
Gemini-001	A	ES	+0,0041	+0,0031	+0,0039
Gemini-001	A	M	+0,0008	+0,0030	+0,0017
Gemini-001	A	R	+0,0036	+0,0038	+0,0000
OpenAI-3-large	S	ES	−0,0002	+0,0002	−0,0001
OpenAI-3-large	S	M	+0,0000	+0,0001	+0,0000
OpenAI-3-large	S	R	+0,0000	+0,0000	+0,0000
OpenAI-3-large	A	ES	−0,0011	+0,0032	−0,0002
OpenAI-3-large	A	M	+0,0006	−0,0008	+0,0007
OpenAI-3-large	A	R	+0,0000	+0,0000	+0,0001
OpenAI-3-small	S	ES	+0,0009	+0,0006	+0,0000
OpenAI-3-small	S	M	+0,0005	+0,0003	+0,0000
OpenAI-3-small	S	R	+0,0000	−0,0001	+0,0000
OpenAI-3-small	A	ES	+0,0006	+0,0007	+0,0000
OpenAI-3-small	A	M	+0,0000	+0,0002	−0,0008
OpenAI-3-small	A	R	+0,0008	+0,0002	−0,0017
MiniLM-L6	S	ES	+0,0000	+0,0000	+0,0000
MiniLM-L6	S	M	+0,0004	+0,0002	+0,0000
MiniLM-L6	S	R	+0,0007	+0,0000	+0,0004
MiniLM-L6	A	ES	+0,0043	+0,0029	+0,0027
MiniLM-L6	A	M	+0,0034	+0,0003	+0,0005
MiniLM-L6	A	R	+0,0030	+0,0004	+0,0005

TABLE S10 – Sensibilité au nombre de clusters k de la variante par clustering, NFCorpus. Variations de NDCG@10 calculées sur l'ensemble des requêtes du découpage initial. *Gate* : S strict, A adaptatif ; SS : *search strictness* (ES, M, R).

Encodeur	*Gate*	SS	$k = 3$	$k = 5$	$k = 10$
Titan-v1	S	ES	+0,0013	+0,0001	+0,0023
Titan-v1	S	M	+0,0035	+0,0017	+0,0015
Titan-v1	S	R	+0,0005	+0,0002	+0,0002
Titan-v1	A	ES	+0,0009	+0,0010	+0,0005
Titan-v1	A	M	+0,0001	+0,0000	+0,0000
Titan-v1	A	R	+0,0000	+0,0000	+0,0001
Gemini-001	S	ES	+0,0084	+0,0081	+0,0105
Gemini-001	S	M	+0,0169	+0,0028	+0,0043
Gemini-001	S	R	+0,0050	+0,0000	+0,0169
Gemini-001	A	ES	+0,0249	+0,0313	+0,0140
Gemini-001	A	M	+0,0021	+0,0006	+0,0024
Gemini-001	A	R	+0,0154	−0,0002	+0,0139
OpenAI-3-large	S	ES	+0,0068	+0,0087	+0,0033
OpenAI-3-large	S	M	+0,0087	+0,0002	+0,0121
OpenAI-3-large	S	R	+0,0012	+0,0031	+0,0126
OpenAI-3-large	A	ES	+0,0000	+0,0023	−0,0001
OpenAI-3-large	A	M	+0,0001	+0,0000	+0,0000
OpenAI-3-large	A	R	+0,0015	+0,0013	+0,0022
OpenAI-3-small	S	ES	+0,0063	+0,0041	+0,0067
OpenAI-3-small	S	M	+0,0020	+0,0045	+0,0037
OpenAI-3-small	S	R	+0,0042	+0,0028	+0,0023
OpenAI-3-small	A	ES	+0,0058	+0,0033	+0,0000
OpenAI-3-small	A	M	+0,0001	+0,0010	+0,0000
OpenAI-3-small	A	R	+0,0000	+0,0001	+0,0040
MiniLM-L6	S	ES	+0,0007	−0,0003	+0,0000
MiniLM-L6	S	M	+0,0001	−0,0016	−0,0017
MiniLM-L6	S	R	−0,0005	+0,0008	−0,0023
MiniLM-L6	A	ES	+0,0000	−0,0005	+0,0000
MiniLM-L6	A	M	+0,0000	+0,0000	−0,0003
MiniLM-L6	A	R	−0,0008	−0,0012	+0,0000

TABLE S11 – Sensibilité au nombre de clusters k de la variante par clustering, SciDocs. Variations de NDCG@10 calculées sur l'ensemble des requêtes du découpage initial. *Gate* : S strict, A adaptatif ; SS : *search strictness* (ES, M, R).

Encodeur	*Gate*	SS	$k = 3$	$k = 5$	$k = 10$
Titan-v1	S	ES	+0,0054	+0,0182	+0,0100
Titan-v1	S	M	+0,0306	+0,0032	+0,0054
Titan-v1	S	R	+0,0722	+0,0137	+0,0028
Titan-v1	A	ES	+0,0000	+0,0000	+0,0000
Titan-v1	A	M	+0,0000	+0,0000	+0,0000
Titan-v1	A	R	+0,0000	+0,0000	+0,0000
Gemini-001	S	ES	+0,0019	–	–
Gemini-001	S	M	+0,0014	–	–
Gemini-001	S	R	+0,0019	–	–
Gemini-001	A	ES	+0,0000	–	–
Gemini-001	A	M	+0,0000	–	–
Gemini-001	A	R	+0,0000	–	–
OpenAI-3-large	S	ES	+0,0385	+0,0469	+0,0518
OpenAI-3-large	S	M	+0,0119	+0,0067	+0,0290
OpenAI-3-large	S	R	+0,0188	+0,0061	+0,0358
OpenAI-3-large	A	ES	+0,0103	+0,0001	+0,0226
OpenAI-3-large	A	M	+0,0099	+0,0032	+0,0054
OpenAI-3-large	A	R	+0,0056	+0,0042	+0,0133
OpenAI-3-small	S	ES	+0,0007	+0,0009	+0,0007
OpenAI-3-small	S	M	+0,0031	+0,0012	+0,0072
OpenAI-3-small	S	R	+0,0042	+0,0025	+0,0084
OpenAI-3-small	A	ES	+0,0000	+0,0000	+0,0000
OpenAI-3-small	A	M	+0,0000	+0,0000	+0,0000
OpenAI-3-small	A	R	+0,0000	+0,0000	+0,0000
MiniLM-L6	S	ES	+0,0014	+0,0107	+0,0111
MiniLM-L6	S	M	+0,0035	+0,0196	+0,0182
MiniLM-L6	S	R	+0,0051	+0,0121	+0,0199
MiniLM-L6	A	ES	+0,0000	+0,0000	+0,0000
MiniLM-L6	A	M	+0,0000	+0,0000	+0,0000
MiniLM-L6	A	R	+0,0000	+0,0000	+0,0000

TABLE S12 – Sensibilité au nombre de clusters k de la variante par clustering, SciFact. Variations de NDCG@10 calculées sur l'ensemble des requêtes du découpage initial. *Gate* : S strict, A adaptatif ; SS : *search strictness* (ES, M, R). – : configuration non exécutable, le nombre d'erreurs résiduelles étant inférieur au nombre de clusters demandé.

Jeu	Encodeur	Exéc. globales	Durée moy.	Exéc. clustering	Durée moy.
ArguAna	Titan-v1	6	10,6	18	28,7
ArguAna	Gemini-001	6	10,5	18	13,8
ArguAna	OpenAI-3-large	6	6,7	18	42,0
ArguAna	OpenAI-3-small	6	6,1	18	37,3
ArguAna	MiniLM-L6	6	8,5	18	34,0
NFCorpus	Titan-v1	6	41,2	18	18,1
NFCorpus	Gemini-001	6	23,4	18	9,7
NFCorpus	OpenAI-3-large	6	23,1	18	11,2
NFCorpus	OpenAI-3-small	6	25,5	18	11,4
NFCorpus	MiniLM-L6	6	32,9	18	12,0
SciDocs	Titan-v1	6	32,0	18	20,0
SciDocs	Gemini-001	6	30,4	18	15,8
SciDocs	OpenAI-3-large	6	29,3	18	20,3
SciDocs	OpenAI-3-small	6	32,1	18	20,5
SciDocs	MiniLM-L6	6	19,5	18	15,5
SciFact	Titan-v1	6	5,6	18	9,5
SciFact	Gemini-001	6	15,6	6	2,8
SciFact	OpenAI-3-large	6	5,2	18	17,5
SciFact	OpenAI-3-small	6	3,5	18	7,4
SciFact	MiniLM-L6	6	5,7	18	7,0
Tous les couples		120	18,4	348	18,2

TABLE S13 – Coût de calcul : durée moyenne par exécution aboutie, en minutes, selon la variante. Les exécutions étant indépendantes et parallélisées, la somme des durées ne correspond pas à la durée totale de la campagne.

Jeu	Encodeur	Dim.	Corpus	NDCG@10	MRR	Erreurs	ΔNDCG@10 test
ArguAna	Gemini-001	3072	8674	0,5762	0,4565	0,89	+0,1626
ArguAna	OpenAI-3-large	3072	8674	0,4100	0,2846	1,00	+0,0535
ArguAna	OpenAI-3-small	1536	8674	0,4018	0,2802	1,00	+0,0506
SciFact	Titan-v1	1024	5183	0,7324	0,7019	0,39	+0,0323
SciFact	OpenAI-3-large	3072	5183	0,7700	0,7409	0,35	+0,0278
SciDocs	Gemini-001	3072	25657	0,2411	0,4025	0,73	+0,0220
ArguAna	Titan-v1	1024	8674	0,3654	0,2567	1,00	+0,0116
ArguAna	MiniLM-L6	384	8674	0,3727	0,2592	1,00	+0,0113
SciDocs	OpenAI-3-large	3072	25657	0,2231	0,3767	0,75	+0,0099
SciFact	MiniLM-L6	384	5183	0,6488	0,6182	0,49	+0,0077
SciFact	OpenAI-3-small	1536	5183	0,7221	0,6868	0,41	+0,0065
NFCorpus	Titan-v1	1024	3633	0,3257	0,5441	0,54	+0,0043
SciDocs	Titan-v1	1024	25657	0,2072	0,3591	0,77	+0,0042
NFCorpus	Gemini-001	3072	3633	0,4097	0,6235	0,47	+0,0041
SciDocs	OpenAI-3-small	1536	25657	0,1922	0,3367	0,78	+0,0018
NFCorpus	MiniLM-L6	384	3633	0,3163	0,5148	0,58	+0,0017
NFCorpus	OpenAI-3-large	3072	3633	0,3975	0,6123	0,48	+0,0012
SciFact	Gemini-001	3072	5183	0,9931	0,9903	0,02	+0,0000
NFCorpus	OpenAI-3-small	1536	3633	0,3598	0,5668	0,54	−0,0037
SciDocs	MiniLM-L6	384	25657	0,2040	0,3542	0,78	−0,0040

TABLE S14 – Caractéristiques des couples pour la configuration retenue sur le découpage initial, triées par gain de NDCG@10 en test sur ce découpage. Dim. : dimension des embeddings ; Corpus : nombre de documents ; NDCG@10 et MRR : valeurs avant correction ; Erreurs : part initiale des requêtes dont le premier résultat n'est pas pertinent.